

Đội: ĐỔI MỚI

2 Thành viên – Phòng Đổi mới và Ứng dụng công nghệ số - Khối Công nghệ:

Phùng Đức Mạnh
Nguyễn Văn Bằng Nam

Track 2: AI FOR MY TEAM

Team Knowledge Assistant

MSB đang hướng tới **AI-First Banking**, nhưng tri thức dự án vẫn **rải rác ở nhiều nơi** — code, Jira, Confluence, họp/chat và rất nhiều nguồn thông tin quan trọng khác không được ghi lại, không được liên kết với nhau và mất theo khi người rời nhóm hoặc dự án kết thúc. Team ĐỔI MỚI tập trung giải quyết vấn đề: **1 nền tảng hợp nhất mọi nguồn tri thức** dự án, có thể truy vết thông tin chi tiết ngay cả khi dự án kết thúc hoặc thành viên rời nhóm, mở rộng liên tục, trả lời có trích dẫn.

- 1 – Vấn đề
- 2 – Giải pháp
- 3 – Cách hoạt động (Demo – Điểm khác biệt – An toàn, tin cậy)
- 4 – Giá trị mang lại – Người hưởng lợi
- 5 – Chuẩn và khung tham chiếu
- 6 – Mở rộng và phát triển kho tri thức

1 - VẤN ĐỀ

Tri thức dự án nằm rải rác ở nhiều nơi không có mối liên kết, và có thể mất khi dự án kết thúc hoặc người rời nhóm



Source code

Kiến trúc thật nằm trong code, không ai rảnh đọc hết



Jira backlog

Ticket nào track bug nào, ai còn nhớ chính xác



Confluence

BRD/SRS viết ra rồi ít ai quay lại đọc



Meeting/chat

Quyết định thật nói miệng, không ghi đâu cả



Email

Xác nhận quan trọng nằm trong hộp thư cá nhân



Thiết kế/diagram

Sơ đồ kiến trúc nằm rải rác trong file cá nhân



Log sự cố/CI-CD

Nguyên nhân sự cố cũ không tra lại được



Tài liệu local

Spec, báo cáo Office/PDF nằm rải rác trong máy cá nhân

CONTEXT

AI-First Banking, giải bài toán thật

PROBLEM

> Nhiều nguồn tách biệt

IMPACT

> Phòng Đổi mới & Ứng dụng từng mất nhiều vòng truy vết thủ công

ROOT CAUSE

> Không có index chung


OUTCOME

> 1 câu hỏi, trích dẫn mọi nguồn


2 - GIẢI PHÁP & KIẾN TRÚC • NGUỒN & CÁCH INDEX NGỮ NGHĨA

Nhiều nguồn dữ liệu, index hiểu ngữ nghĩa — không chỉ đếm từ khoá

8 NGUỒN DỮ LIỆU • 4 ĐANG CHẠY



CÁCH INDEX NGỮ NGHĨA • 4 BƯỚC



 normalize-engine đã có converter thật cho .docx/.pptx/.xlsx/.pdf/.msg/.eml/.html — **bật thêm 1 nguồn = trả thư mục, không viết lại engine.** Source code không qua bước “tóm tắt trước”. Hiện index được cập nhật bằng lệnh chạy tay; tự cập nhật khi code đổi là thiết kế kế tiếp.

3 - 1 CÂU HỎI HOẠT ĐỘNG THỂ NÀO & PHỐI HỢP ĐA NGUỒN

1 câu hỏi, 5 bước xử lý, 4 nguồn bổ sung không xung đột ngầm



BƯỚC 2 · Chế độ tìm Hybrid

Từng có lỗi: câu hỏi có mã ticket bị ép vào “tìm chính xác”, bỏ sót nội dung liên quan. Nay chạy hybrid: từ khoá + vector cùng lúc.

Đảm bảo chính xác qua 4 nguyên tắc

- ✓ Chỉ trả lời từ ngữ cảnh tìm được
- ✓ Mọi câu trả lời kèm trích dẫn
- ✓ Nhấn độ tin cậy hiện kèm nguồn
- ✓ Code không qua tóm tắt trước

4 NGUỒN BỔ SUNG CHO NHAU



KHI 2 NGUỒN KHỚP NHAU

Độ tin cậy được NÂNG lên — càng nhiều nguồn độc lập xác nhận, reliability càng cao



KHI 2 NGUỒN MÂU THUẤN

KHÔNG âm thầm chọn 1 bên — cả 2 xuất hiện kèm trích dẫn riêng, tự đối chiếu

3 - DEMO TRÊN HỆ THỐNG THẬT • KỊCH BẢN NOTIFYHUB • DỮ LIỆU GIẢ LẬP

1 câu hỏi, trả lời trích dẫn cả 4 nguồn cùng lúc

TKA-1 thông báo thanh toán mất

Theo TKA-1, vì sao thông báo thanh toán bị mất âm thầm, code xử lý retry thế nào, và team quyết định sửa gì?

• **TKA-1 — Thông báo thanh toán mất âm thầm**

Vì sao mất âm thầm: trong `notify-service/retry.py`, hàm `send_with_retry()` khi hết cả `MAX_RETRIES` (=3) mà gateway vẫn lỗi thì chỉ `logger.error(...)` rồi `return False` — **không bắn alert nào ra ngoài** (không Slack, không PagerDuty, không nâng mức độ nghiêm trọng). Vì vậy đội vận hành không hề biết thông báo đã "chết", cho tới khi khách hàng chủ động gọi lên hỏi. (TKA-1.md, retry.md)

Code retry hiện tại (`notify-service/retry.py`):

- Thử tối đa `MAX_RETRIES = 3` lần, mỗi lần thất bại (`NotifyDeliveryError`) log `warning` kèm số lần thử.
- Chờ giữa các lần theo `RETRY_BACKOFF_SECONDS(=2) * attempt` (backoff tăng dần: 2s, 4s).
- Hết 3 lần vẫn lỗi → log `error` duy nhất, `return False`, không có nhánh cảnh báo nào khác. Đây chính là gap.

Quyết định team (Sprint Planning 2026-09-19, owner Nam, PM Hương theo dõi):

1. Nâng `MAX_RETRIES` từ 3 → 5, giảm khả năng bỏ cuộc quá sớm khi gateway chỉ lỗi thoáng qua (transient error).
2. Thêm cảnh báo Slack vào kênh `#notify-service-alerts` (kèm `payment_id`) ngay khi hết retry mà vẫn thất bại, để vận hành biết ngay thay vì đợi khách hàng gọi lên.
3. Target xong trước buổi demo; PM Hương xác nhận lại với bên vận hành khi lên production.

(sprint-planning note, xác nhận thêm qua whiteboard OCR cùng buổi họp)

Lưu ý: tenant này (`tenants/demo/teamassistant`) là dữ liệu giả lập cho MSB AI Hackathon 2026, không phải dữ liệu MSB thật — không nằm trong bảng menu tenant chính ở `CLAUDE.md` nhưng có đăng ký hợp lệ trong `tenants/registry.yaml`.

Test thật, không chỉ mockup

- ✓ Site Jira Cloud thật, qua MCP
- ✓ Trang Confluence thật, cùng credential Jira
- ✓ Capture Zalo + OCR local qua Chrome extension
- ✓ 567 chunk / 48 file code thật đã index sẵn

TRÍCH DẪN TỪ 4 NGUỒN

📋 Jira TKA-1

📖 Confluence kiến trúc

🔗 source-code/
retry.py

🗣️ MoM sprint
planning
(Zalo/OCR)

3 - ĐIỂM KHÁC BIỆT • SO VỚI CÁCH LÀM HIỆN NAY

Khác gì trợ lý AI theo từng công cụ: nổi tri thức của cả dự án vào một câu hỏi

	Trợ lý AI gắn với từng công cụ (ví dụ Rovo, Kiro, Copilot)	Chatbot AI đa dụng (ví dụ Claude, GPT)	Team Knowledge Assistant
Trọng tâm	Mỗi công cụ gắn với hệ của mình, ví dụ Rovo (Atlassian), Kiro (AWS), Copilot (Microsoft/GitHub)	Hỏi đáp đa dụng, không gắn với kho tri thức của dự án	Nổi code, Jira, Confluence, hộp/chat của dự án trong 1 câu hỏi
Hộp và chat Zalo	Nội dung hộp, chat ngoài hệ của từng công cụ thường nằm ngoài phạm vi	Chỉ biết những gì được dán vào cuộc hội thoại	Người dùng tự thu Zalo bằng 1 click, OCR chạy local
Trích dẫn, đối chiếu	Thường mạnh ở tìm và soạn trong một hệ; đối chiếu chéo nguồn khác loại ít là trọng tâm	Không có dữ liệu dự án để đối chiếu, không chỉ ra nguồn nội bộ	Mỗi ý kèm trích dẫn + nhãn độ tin cậy; nguồn mâu thuẫn thì hiện cả 2 bên
Kiểm soát dữ liệu	Theo chính sách của từng nhà cung cấp	Dữ liệu dự án do người dùng tự dán vào, khó kiểm soát	Lọc theo visibility của tài liệu; dữ liệu demo giả lập; đổi nhà cung cấp model bằng cấu hình
Mở rộng	Theo lộ trình của từng nhà cung cấp	Không áp dụng	Mỗi lane vận hành độc lập theo chuẩn chung, sau đó nối thành kho chung MSB

So sánh ở mức định hướng theo nhóm giải pháp; tên sản phẩm chỉ là ví dụ minh họa.

3 - CONFIDENT • AN TOÀN & TIN CẬY

An toàn và bảo mật: đã có gì, và lộ trình theo chuẩn quốc tế

RỦI RO	HIỆN TRẠNG	LỘ TRÌNH THEO CHUẨN QUỐC TẾ • CHƯA TRIỂN KHAI
Truy cập trái quyền	 Lọc theo visibility của tài liệu (khách / chủ sở hữu), chưa gắn danh tính từng người	Phân quyền theo từng người: truyền danh tính vào engine, gắn nhãn nhạy cảm cho chunk, lọc quyền lúc truy xuất. Chuẩn: ISO/IEC 27001:2022 (A.5.12–5.13) • OWASP LLM08:2025
Dữ liệu gửi ra API ngoài	 Model cấu hình được, không gắn cứng nhà cung cấp; demo hiện dùng OpenAI; dữ liệu demo giả lập	Che/ẩn danh trường nhạy cảm trước khi gửi; dữ liệu mức cao chỉ xử lý local/GreenNode; rà soát điều khoản nhà cung cấp. Chuẩn: OWASP LLM02:2025 • ISO/IEC 27001:2022 (A.5.19–5.23)
Thu thập chat Zalo	 Người dùng tự chủ động thu bằng 1 click; OCR chạy local	Chỉ thu chat công việc, thông báo trong nhóm, loại thông tin cá nhân khỏi index. Chuẩn: ISO/IEC 27001:2022 (A.5.34)
Prompt injection từ ticket, tài liệu, chat	 Chưa có lớp phòng vệ riêng	Tách nội dung truy xuất khỏi chỉ dẫn hệ thống, chỉ cấp quyền đọc, kiểm tra đầu ra và trích dẫn, red-team định kỳ. Chuẩn: OWASP LLM01:2025
Câu trả lời sai hoặc thiếu căn cứ	 Chỉ trả lời từ ngữ cảnh tìm được, mọi câu trả lời kèm trích dẫn	Chấm nhãn tin cậy bằng tín hiệu giải thích được: điểm truy xuất, độ bám nguồn, số nguồn khác loại, độ mới; đo bằng bộ câu hỏi chuẩn (RAGAS). Chuẩn: OWASP LLM09:2025 (Misinformation) • NIST AI RMF 1.0

Cột lộ trình là kế hoạch, chưa triển khai. Tham chiếu: OWASP Top 10 for LLM Applications 2025, ISO/IEC 27001:2022, NIST AI RMF 1.0.

4 - GIÁ TRỊ CHO MSB • REACH & IMPACT • THEO DỰ ÁN THẬT

Không chỉ giúp đội thi — Mọi người dùng đều hưởng lợi, ở mức độ khác nhau theo từng dự án



IMPACT • NỀN TẢNG ĐÃ DÙNG

Engine nền đã phục vụ báo cáo và quản trị backlog/task công việc (Magnet, eKYC); bản thi mới demo trên NotifyHub



IMPACT • EXPERIENCE

Trích dẫn ngay trong chat — không hỏi vòng qua nhiều người



IMPACT • STRATEGIC ALIGNMENT

Bám định hướng AI-First Banking Tổng Giám đốc đã kêu gọi

MỨC HƯỞNG LỢI THEO DỰ ÁN THẬT

eKYC

Cao

Nhiều đối tác kỹ thuật, SRS/BRD lớn

Confluence + Email

Magnet

Cao

Nhiều bên phối hợp, nhiều kênh quyết định

Meeting/chat + Code

DIP

Trung bình

Nhiều đợt go-live nối tiếp, MoM dày đặc

Jira + Meeting/chat

MSBPay

Trung bình

Backlog lớn, ticket liên quan chéo

Jira + Code

MConnect

Trung bình

Giai đoạn đầu, tài liệu còn ít

Confluence + Jira

Hiệu quả hiện chưa đo định lượng. Mức hưởng lợi do nhóm đánh giá theo 3 tiêu chí: số nguồn dùng song song, tần suất phối hợp liên phòng ban/đối tác, mức độ thay đổi kiến trúc & quyết định theo thời gian.

4 - CONFIDENT • AI ĐƯỢC LỢI • TRƯỚC/SAU THEO VAI TRÒ

Trước/sau theo vai trò — ai được lợi gì từ kho tri thức

VAI TRÒ	TRƯỚC KHI CÓ KHO TRI THỨC	SAU KHI CÓ KHO TRI THỨC
KỸ THUẬT		
 Developer	Hỏi đồng nghiệp/tự đọc lại code cũ để hiểu vì sao viết vậy	→ Hỏi thẳng, nhận trích dẫn code + lý do quyết định
 Tech Lead	Tự nhớ/lục nhiều trang Confluence để đối chiếu kiến trúc đã duyệt	→ Tra cứu tức thời, đối chiếu kiến trúc đã duyệt kèm nguồn
 QA/Kiểm thử	Đối chiếu thủ công yêu cầu, ticket, code và quyết định hợp để viết ca kiểm thử	→ Hỏi 1 câu, thấy yêu cầu, ticket, code liên quan và quyết định — có trích dẫn
 Người mới	Mất nhiều ngày hỏi lại người cũ để hiểu hệ thống	→ Tự tra cứu từ ngày đầu, giảm phụ thuộc người hướng dẫn
NGHIỆP VỤ & ĐIỀU HÀNH		
 BA/Nghịệp vụ	Mất công tìm vì sao yêu cầu đổi trong BRD/SRS, họp và chat; khó chứng minh điều đã chốt	→ Tra cứu yêu cầu, quyết định kèm trích dẫn; BRD/SRS và code mâu thuẫn thì thấy cả hai phía
 PM/Scrum	Backlog Jira và MoM tách rời, dễ báo cáo sai tình trạng	→ 1 nguồn tổng hợp backlog + quyết định, báo cáo đúng hơn
 Chiến lược	Muốn biết dự án đã cam kết gì, vì sao đổi hướng phải hỏi nhiều người, đọc nhiều báo cáo	→ Nắm nhanh đã quyết gì, vì sao, còn gì tồn đọng; xuyên dự án khi các lane được liên kết
 Quản lý/Kiểm soát	Không thấy toàn cảnh tri thức dự án, khó audit quyết định	→ Tra cứu xuyên suốt, nguồn gốc quyết định minh bạch

5 - CONFIDENT • 10 CHUẨN & KHUNG THAM CHIẾU ĐÚNG PHẠM VI

10 chuẩn và khung tham chiếu — mỗi chuẩn gắn với đúng một phần của hệ thống

3 KM & dữ liệu hệ thống quản lý tri thức; chunk cần metadata + chất lượng	ISO 30401:2018 → Toàn hệ thống là 1 hệ thống quản lý tri thức	W3C PROV (2013) → Trích dẫn nguồn = truy vết nguồn gốc thông tin	ISO/IEC 25012:2008 → Metadata và chất lượng cho từng chunk
3 RAG/LLM đúng kỹ thuật & rủi ro đang chạy	RAG (Lewis et al., 2020) → Truy xuất rồi sinh câu trả lời có trích dẫn	RAGAS (2023) → Chấm điểm tìm kiếm & trả lời — bước tiếp theo, chưa chạy	OWASP LLM Top 10 (2025) → Khung rủi ro cho lớp bảo mật của hệ thống
3 Quản trị AI hệ thống LÀ 1 AI system	ISO/IEC 42001:2023 → Khung quản lý AI khi vận hành nhiều lane	ISO/IEC 23894:2023 → Nhận diện, xử lý rủi ro AI — nền cho lộ trình bảo mật	NIST AI RMF 1.0 (2023) → Govern-Map-Measure-Manage để đo và quản lý rủi ro
1 An toàn TT lọc theo visibility; phân quyền từng người là bước tiếp theo	ISO/IEC 27001:2022 → Phân loại, gắn nhãn và phân quyền thông tin (Annex A)		

6 - MỞ RỘNG VÀ PHÁT TRIỂN KHO TRI THỨC

Mỗi lane vận hành độc lập theo chuẩn chung, rồi nối thành kho tri thức chung của MSB



HIỆN TẠI

Engine đã dùng thật

- Cùng engine đã phục vụ báo cáo, backlog (Magnet, eKYC)
- Bản thi mới demo trên dữ liệu giả lập NotifyHub
- 4/8 nguồn dữ liệu đang chạy



BƯỚC 1

Mỗi lane chạy độc lập

- DIP, Magnet, eKYC, MSBPay, MConnect tự vận hành kho tri thức riêng
- Không lane nào phải chờ lane khác



SAU NÀY

Liên kết hoặc đổ chung

- Liên kết các lane với nhau
- Hoặc đổ chung vào một biển tri thức của toàn MSB

CHUẨN CHUNG GIỮA CÁC LANE

normalize-engine

Metadata theo chunk

Lọc theo visibility của tài liệu

Trích dẫn nguồn

Phân quyền theo từng người
(thiết kế)

Nhờ dùng chung một chuẩn, việc liên kết hoặc gộp kho về sau không phải làm lại từng lane.

6 - TỔNG KẾT THEO ĐÚNG THANG ĐIỂM & BƯỚC TIẾP THEO

Đã chạy thật trên 4 nguồn — Có thể mở rộng



REACH

- Đúng pattern BTC nêu
- Nhu cầu hàng ngày



IMPACT

- Engine nền đã dùng ở Magnet, eKYC
- Bám AI-First Banking
- 5 dự án được xếp mức hưởng lợi



CONFIDENT

- Demo chạy thật
- 10 chuẩn & khung tham chiếu

BƯỚC TIẾP THEO



1

Bật 4 nguồn tiếp theo: email, tài liệu local, thiết kế, log sự cố



2

Tự cập nhật index khi code đổi; đa ngôn ngữ (hiện Python)



3

Đo chất lượng tìm kiếm và trả lời bằng bộ câu hỏi chuẩn (RAGAS)



4

Phân quyền theo từng người; chống prompt injection (OWASP)

RAGAS ĐO GÌ? • KẾ HOẠCH, CHƯA CHẠY

Tìm đúng chưa? Đoạn tìm về có liên quan và đủ thông tin không (context precision/recall)

Trả lời có bám nguồn không? Mỗi ý có căn cứ trong đoạn đã tìm, không bịa (faithfulness)

Có đúng câu hỏi không? Câu trả lời có giải quyết đúng điều được hỏi (answer relevancy)



Cảm ơn Ban Giám Khảo

Phùng Đức Mạnh & Nguyễn Văn Bằng Nam · Team Knowledge Assistant

AI FOR MY TEAM · MSB AI HACKATHON 2026